

# 深度学习在植物识别中的应用

王健<sup>1</sup>

2017 年 11 月 12 日

(1 中国科学院软件研究所, 北京 100190, yt4766269@126.com)

**关键词:** 深度学习, 计算机视觉, 植物, 叶片

**摘要** 本文将图像识别研究的最新进展应用于植物图像识别, 使用深度学习算法进行叶片分类研究, 探究了三种流行的卷积神经网络模型在植物叶片分类上的效果, 在经过 25 个训练循环之后, 三种神经网络模型在北美 184 种植物叶片数据集上均取得了较好的分类效果。

## 引言

为了保护物种多样性, 了解一个地区的植物物种组成是非常重要的。但是传统的植物物种判别手段不仅非常复杂和耗时, 而且要求识别人掌握全面的植物知识。而如今, 物种自动识别方向的研究正引起人们的兴趣。我们可以通过照相机、手机等设备进行图像采集, 然后调用物种判别算法, 对采集到的图像数据进行分析, 最终得到具体物种信息。而在上述流程中, 物种判别算法的准确率影响着物种自动识别的好坏, 因此物种判别算法起着至关重要的作用。

而随着深度学习理论的发展与计算机视觉技术的进步, 近年来涌现出了一大批优秀的深度学习模型, 其中包括 Vgg[vgg], Resnet[resnet], Densenet[densenet] 等, 这些深度学习模型在 Imagenet[imagenet] 的 1000 种图像分类的数据集上取得了很好的结果。而植物图像分类问题与 Imagenet 图像分类问题类似, 均可以用深度学习模型很好的解决。因此, 本文将如上三种深度学习模型应用于植物图像识别, 进行植物叶片照片的分类研究。

## 深度学习与图像识别

2006 年, Hinton 提出了深度学习。之后深度学习在诸多领域取得了巨大成功, 受到广泛关注。神经网络能够重新焕发青春的原因有几个方面: 首先, 大规模训练数据的出现在很大程度上缓解了训练过拟合的问题。例如, ImageNet 训练集拥有上百万个有标注的图像。其次, 计算机硬件的飞速发展为其提供了强大的计算能力, 一个 GPU 芯片可以集成上千个核。这使得训练大规模神经网络成为可能。第三, 神经网络的模型设计和训练方法都取得了长足的进步。

而深度学习在物体识别中有非常重要的应用, 其中最重要的进展体现在 ImageNet ILSVRC 挑战中的图像分类任务。传统计算机视觉方法在此测试集上最低的错误率是 26.172%。2012 年, Hinton 的研究小组利用卷积网络把错误率降到了 15.315%。在此之后, 不断有新的网络结构被提出出来, 网络的深度也不断增加, 2014 年, Andrew Zisserman 等人提出了 VGG 全卷积网络, 在 Imagenet 数据集上取得了 6.8% 的 top-5 错误率。2015 年, 微软亚洲研究院的何凯明等人提出了 Resnet, 将网络层数增加到 152 层, 在 Imagenet 数据集上取得了 3.57% 的 top-5 错误率。2016 年, 康奈尔大学的 Kilian Q. Weinberger 等人, 开发出 Densenet 网络结构, 取得了 5.3% 的 top-5 错误率, 同时大大加快的网络训练的速度。

虽然深度学习在 ImageNet 上取得了巨大成功，但是很多应用的训练集是较小的，在此种情况下，可以将 ImageNet 上训练得到的模型作为起点，利用目标训练集和反向传播对其进行继续训练，将模型适应到特定的应用。此时 ImageNet 起到预训练的作用。

本文使用了以上三种优秀的神经网络结构，采用了 Leafsnap 数据集，利用植物的叶片照片进行植物图像分类的研究。

## 相关工作

近年出现了一些将计算机视觉的方法应用于植物学当中的文章，其中一个经典的研究方向是计算机视觉应用于植物形态学的分析。人工进行形态学的分析耗时耗力，但是如果使用机器学习算法进行自动分析，则可大大提升效率。例如，在最近 Jordan 等人发表的文章中 [count]，采用了卷积神经网络对鼠耳芥照片进行分析，实现对鼠耳芥叶片数目的统计。

## 机器学习模型

### 实验部分

#### 数据集

本文使用了 Leafsnap[leafsnap] 数据集，数据集中包括美国北部 184 种植物叶子图片，共计 23,147 张图片，其中部分图片如图 1 所示例。这些数据图片在光照，阴影，清晰度等方面变化很大。该数据集可以通过如下网站下载得到：<http://leafsnap.com/dataset/>




图 1: 数据集原图

在获得数据集之后，需要对原始图片进行预处理，首先将所有图片按照 3: 1 的比例生成训练集与测试集，对于所有图片，将其从图像中间裁剪至 256 像素 × 256 像素大小，然后进一步随机裁剪至 224 × 224 像素大小，然后将图像随机水平翻转，最后将图像归一化，归一化后的图片如图 2 所示。

#### 训练步骤

在数据预处理完成和选定模型完成之后，可以进行训练参数的设定，这里，我们将三种模型的参数统一设定如下：




图 2: 预处理后图片

- 学习速率: 0.001
- 动量: 0.9
- batch\_size: 4

同时，在训练过程中采用了已经预先在 Imagenet 数据集上训练好的网络参数数据作为预训练的结果。

## 训练结果

vgg19 在该数据集上获得了 92.54% 的准确率，训练的 loss 曲线如图 3 所示：




图 3: vgg 训练曲线

Resnet 在该数据集上获得了 93.25% 的准确率，训练时的 loss 曲线如图 4 所示：




图 4: Resnet 训练曲线




图 5: Densenet 训练曲线

densenet 在该数据集上获得了 93.85% 的准确率，训练时的 loss 曲线如图 5 所示：

由上可见，三种模型对植物叶片图像分类的任务均有比较好的效果，而其中 Densenet 和 Resnet 训练的效果稍好，并且训练收敛的速度较快。

## 结果分析

取 densenet 的数据进行结果分析，错误率较高的几个类别分别为：

植物名称	错误率
prunus_sargentii	27.4%
prunus_virginiana	23%
quercus_muehlenbergii	35%
pinus_virginiana	55%
magnolia_stellata	50%

这些类别的叶片形状大致相似，比较难以区分，如图 6 所示：




图 6: 错误率较高的几个类别

观察图 6，也有可能是数据集存在一些错误导致识别错误率较高。

## 结论

我们在这篇论文中实现了三种深度学习模型，在已有的叶片数据集上进行了训练，显示出较好的结果，这些模型均可以用于植物图像识别的算法。但是这些算法依赖于大量的数据集，对植物叶片数据进行采集

和人工分辨也需要耗费相当大的精力。另外，这些算法依赖于服务器上 GPU 的大规模运算，如果能将其适配于手持设备（如手机）上，则能够更加便于工作人员进行物种的调查采样。